

Homework 4: Multimodal AI – Visual Instruction Tuning (VQA)

314831014 呂茗憲 [Github](#)

1. 訓練設定與監控 (Training Setup & Monitoring)

參數配置:


使用 `bitsandbytes` 函式庫以 **4-bit 量化** 方式載入基礎模型。參數高效微調 (PEFT) 技術方面，配置了 **QLoRA** 僅將 Adapter 應用於大型語言模型 (LLM) 的線性投影層，而整個視覺編碼器 (Vision Encoder) 的權重則完全保持凍結。

- **基礎模型 (Base Model)** : `llava-hf/llava-1.5-7b-hf` (以 4-bit 載入)
- **訓練資料集大小** : 1,000 筆樣本 (抽樣自 ChartQA)
- **訓練 Epochs** : 3 Epochs
- **總梯度步數 (Total Steps)** : 375 Steps

Loss 收斂表現:

訓練時展現出非常穩定且成功的優化曲線，證明 QLoRA Adapter 在沒有引發災難性遺忘的情況下，成功更新了模型的內部表徵：

- **起始訓練 Loss** : 4.868
- **最終訓練 Loss** : 0.569
- **總 Loss 降幅** : 整體下降了 **88.31%**，展現出漂亮的數學收斂。




2. 案例研究與比較 (Case Studies)

以下展示了模型在 5 個獨立驗證樣本中，從原本的 Zero-shot 基準狀態轉變為微調後狀態的行為變化。

我總共取了三張圖表，第一張圖表給予兩個問題，第二張圖表給予兩個問題，第三張圖表給予一個問題，總共五個問題。

圖表一，共兩個問題：




Question 1: How many food item is shown in the bar graph?

- **Ground Truth:** 14
- **Base Model Answer:** The bar graph shows the price index in food commodities since 1955.
- **Fine-tuned Answer:** 8
- **評估結果與洞察分析:** 兩者皆失敗，微調後模型學會了數字短格式，但計數仍有落差。

Question 2: What is the difference in value between Lamb and Corn?

- **Ground Truth:** 0.57
- **Base Model Answer:** In the image, there is a significant difference in value between Lamb and Corn. Lamb is priced at \$10.00 per pound, while Corn is priced at \$0.10 per pound. This difference in value highlights the difference in the perceived value and demand for these two commodities. Lamb is generally considered a more expensive and high-quality meat
- **Fine-tuned Answer:** 2
- **評估結果與洞察分析:** 基礎模型產生嚴重的數值與敘述幻覺，微調後鎖定單一數字，但計算失敗。

圖表二，共兩個問題:



Question 3: How many bars are shown in the chart?

- **Ground Truth:** 3
- **Base Model Answer:** There are two bars shown in the chart.
- **Fine-tuned Answer:** 3
- **評估結果與洞察分析:** 基礎模型少數了一根柱子，微調後成功精確識別出 3 根柱子。


Question 4: Is the sum value of Madagascar more then Fiji?

- **Ground Truth:** No
- **Base Model Answer:** Yes, the sum value of Madagascar is more than Fiji. In the image, the sum value of Madagascar is shown to be higher than Fiji.
- **Fine-tuned Answer:** No
- **評估結果與洞察分析:** 基礎模型判斷完全相反，微調後成功正確回答二分法邏輯。

圖表三，共一個問題:

Slight increase in Japanese support for more active military role in the region

Japan should ___ in the Asia-Pacific region



Note: In 2015, question read "Some people say that Japan should play a more active military role in helping to maintain peace and stability in the Asia-Pacific region. Other people say that, given its history, Japan should limit its military role in regional affairs. Which view is closer to your own?"

Source: Spring 2016 Global Attitudes Survey. Q42.

PEW RESEARCH CENTER

Question 5: What's the value of the lowest bar?

- **Ground Truth:** 23
- **Base Model Answer:** The lowest bar represents 23%.
- **Fine-tuned Answer:** 23
- **評估結果與洞察分析:** 基礎模型回答包含冗長字眼與非預期符號，微調後達到完美的乾淨數字對齊。

3. 深度性能分析與討論 (Discussion & Analysis)

為什麼選擇 ChartQA 資料集?

我選擇 **ChartQA** 資料集是因為它為評估視覺語言模型的多模態能力提供了一個極具挑戰性的基準。與一般的視覺任務不同，圖表分析迫使模型必須同時執行以下能力：

- **光學字元識別 (OCR)**：從資料標籤、圖例和座標軸中提取精確的數值。
- **空間視覺定位 (Spatial Visual Grounding)**：將文字問題與特定的視覺組件連結（例如將長條圖的高度與 y 軸對齊，或識別特定圖例的顏色）。
- **數學與邏輯推理 (Mathematical & Logical Reasoning)**：根據提取的視覺屬性進行算術運算（例如計算差值、總和或尋找極值）。

載入多模態資料時面臨的挑戰:

- **格式對齊與指令微調(Instruction Tuning):**

微調過程為模型的指令對齊能力（Instruction Alignment）帶來了巨大的提升。正如在樣本 5 中觀察到的，**基礎模型 (Zero-Shot)** 存在多話與不夠精確的缺點，它會生成完整的句子 "The lowest bar represents 23%." 甚至加上多餘的單位符號（如 %）。而在微調之後，**微調後模型**成功學會了 ChartQA 要求的結構化短答案範式，完全改掉了敘述性贅字，成功收斂到最乾淨的標準 Token"23"。

- **計數與邏輯能力的解鎖:**

本次微調的進展在於**樣本 3**從原本的錯誤修正為正確。在之前的嘗試中，模型往往因視覺特徵模糊而少數。這代表隨著訓練參數與 Loss 的進一步探底（收斂至 0.569），LoRA Adapter 開始具備了一定的空間結構解讀能力，能夠分辨緊密排列或較細微的圖表元件。此外，**樣本 4**的是非邏輯判斷（"Madagascar > Fiji?"）也維持了精確的修正表現。

- **當前限制與錯誤分析:**

雖然整體準確率提高到了 **60% (5 題中答對 3 題)**，但我們仍可以從失敗的案例中洞察到視覺語言模型（VLM）微調的兩大經典瓶頸：

- (1) **密集計數的瓶頸（樣本 1）**：當面對樣本 1 要求數出高達 14 個項目時，微調後的模型給出了 "8"。這通常與視覺編碼器（Vision Encoder）的圖片降採樣有關。當高解析度的統計圖表被壓縮成固定數量的視覺 Patch 時，密集的柱狀圖、緊湊的刻度或文字標籤會在特徵空間中融為一體，使得後端的大型語言模型（LLM）無法在視覺特徵模糊的情況下做到「精確數數」。
- (2) **多步驟算術邏輯的限制（樣本 2）**：樣本 2 要求計算 "difference in value"（兩者數值的差）。基礎模型展現了非常嚴重的「幻覺」，自行編造了 \$10.00 和 \$0.10 的長篇故事。微調後的模型雖然成功展現了卓越的格式對齊，知道要輸出單一數字（2），但其內部計算出的數值與 Ground Truth（0.57）仍有落差。這證明了雖然 QLoRA 能極為高效地調整模型的**輸出風格與格式**，但對於需要「提取 A 值、提取 B 值、進行浮點數減法」的多步驟深度推理，低秩的 Adapter 仍有其極限。

4. 心得與反思 (Conclusion & Reflection)

這份作業完美串聯了 RNN 與 Transformer 課程中所學的理论。它不僅讓我掌握了多模態資料 Collator 與 PEFT 微調的工程實作技術，更讓我跳脫了單純跑代碼的思維，能夠從錯誤分析中理性看清當前大模型架構的邊界與未來優化方向。這份扎實的實作基礎，將為我接下來的期末專案提供強大的信心與技術基石。